

MEMORIA DEL PROYECTO

Machine Learning

Predicción de Cancelaciones Hoteleras

**Optimización de la Gestión de Reservas mediante Algoritmos de
Machine Learning**

Data Science 2026

Autora: Nassirdine El Mourif Fatima

Fecha: Mayo 2026

Centro: The Bridge

1.Introducción

Las cancelaciones de reservas representan uno de los principales problemas dentro del sector hotelero, ya que afectan directamente a la ocupación, la planificación operativa y los ingresos del negocio.

El objetivo principal de este proyecto consiste en desarrollar un modelo de Machine Learning capaz de predecir si una reserva será cancelada antes de la fecha de llegada del cliente.

La finalidad del sistema predictivo es ayudar a anticipar comportamientos de cancelación para mejorar:

- La gestión del inventario hotelero.
- Las estrategias de overbooking.
- La toma de decisiones comerciales.
- La planificación de recursos.

2. Descripción del Dataset

Se trabajó con un dataset de reservas hoteleras que contiene información relacionada con:

- Tipo de hotel.
- Fechas de llegada.
- Segmento de mercado.
- Tipo de depósito.
- Número de adultos, niños y bebés.
- Precio medio diario (ADR).
- Historial del cliente.
- Solicitudes especiales.
- Estado final de la reserva.

La variable objetivo utilizada fue: `is_canceled`

- 0 → Reserva no cancelada.
- 1 → Reserva cancelada.

El dataset presentaba un desbalanceo moderado entre clases; 63% reservas no canceladas, y 37% reservas canceladas

3. Limpieza y Preparación de Datos

Antes del entrenamiento de los modelos se realizó un proceso de limpieza y transformación del dataset.

3.1 Tratamiento de valores nulos

Se analizaron las variables con valores faltantes y se aplicaron diferentes estrategias:

- Eliminación de variables con exceso de nulos.
- Imputación en variables numéricas.
- Sustitución de categorías faltantes.

3.2 Tratamiento de duplicados

Durante el análisis exploratorio se detectó un número elevado de registros duplicados exactos.

Tras revisar la estructura del dataset, se decidió eliminar dichos duplicados para evitar:

- Sesgos en el entrenamiento.
- Riesgo de overfitting.

3.3 Tratamiento de variables categóricas

Se aplicaron distintas técnicas de encoding para convertir las variables categóricas en variables numéricas.

Label Encoding

Se utilizó Label Encoding sobre determinadas variables categóricas debido a que varios de los modelos utilizados estaban basados en árboles de decisión, algoritmos poco sensibles al orden artificial introducido por este tipo de codificación.

Reducción de cardinalidad

En variables como country, se agruparon categorías poco frecuentes bajo la categoría Other para reducir dimensionalidad y mejorar la capacidad de generalización del modelo.

4. Análisis Exploratorio de Datos (EDA)

Durante el EDA se analizaron tanto variables numéricas como categóricas con el objetivo de identificar patrones relacionados con las cancelaciones.

Lead Time: Las reservas realizadas con mucha antelación (lead_time) mostraron una mayor probabilidad de cancelación.

Tipo de depósito: Las reservas con depósitos Non Refund presentaron tasas de cancelación considerablemente menores.

Solicitudes especiales: Los clientes que realizaban más solicitudes especiales mostraban un mayor compromiso con la reserva y cancelan menos.

Parking: Los clientes que solicitaban plazas de parking presentaban una probabilidad significativamente menor de cancelar.

Segmento de mercado: Determinados segmentos de mercado mostraron comportamientos muy diferentes respecto a las cancelaciones.

5. Modelado de Machine Learning

Se entrenaron distintos modelos de clasificación para comparar su capacidad predictiva.

5.1 Regresión Logística

La Regresión Logística se utilizó como modelo baseline.

Resultados

- Recall aproximado: 39%
- Baja capacidad para detectar cancelaciones.

Conclusión: Aunque el modelo mostró estabilidad, presentó limitaciones importantes para identificar correctamente reservas canceladas.

2 Random Forest

Posteriormente se entrenó un modelo Random Forest.

Resultados obtenidos:

- Accuracy: 81%
- Precisión (Clase 1): 78%
- Recall (Clase 1): 45%
- F1-Score (Clase 1): 0.57

Análisis

A diferencia de las pruebas iniciales donde se observaba un alto grado de overfitting (memorización), este modelo logró una mayor estabilidad entre entrenamiento y test. Sin embargo, su capacidad predictiva se mantuvo limitada para el objetivo principal.

El modelo tiene una alta precisión (78%), lo que significa que cuando predecía una cancelación, solía acertar. Sin embargo, su Recall (45%) resultó insuficiente para las necesidades del hotel; el modelo ignoraba más de la mitad de las cancelaciones reales, comportándose de forma conservadora debido al desbalance de los datos. Por este motivo, el modelo fue descartado como candidato final.

5.3 XGBoost

Como solución definitiva, se implementó el algoritmo XGBoost (Extreme Gradient Boosting). Este modelo de boosting construye árboles de forma secuencial, donde cada nuevo árbol intenta corregir los errores de los anteriores, logrando una precisión superior en patrones complejos.

Se implementó el modelo utilizando ajuste de pesos (scale_pos_weight) para compensar el desbalanceo de clases. Este ajuste técnico permitió equilibrar la importancia de las clases, obligando al modelo a prestar más atención a las cancelaciones (clase minoritaria) probando diferentes configuraciones.

Resultados Obtenidos (Datos de Test):

- Accuracy: 80%
- Precision (Clase 1): 60%
- Recall (Clase 1): 87%
- F1-Score (Clase 1): 0.71

Análisis de Desempeño y Justificación de Selección:

- Maximización del Valor de Negocio: El modelo logró elevar el Recall hasta el 87%. Esto significa que el hotel es capaz de identificar correctamente a casi 9 de cada 10 clientes que cancelarán su reserva, permitiendo una gestión de inventario proactiva y minimizando habitaciones vacías.
- Equilibrio Operativo: Aunque la precisión se situó en un 60%, el impacto económico de una "falsa alarma" (tratar a un cliente fiel como posible cancelación) es significativamente menor para el hotel que el coste de una cancelación no detectada. El F1-Score de 0.71 valida que este equilibrio es óptimo.
- Robustez y Generalización: Tras realizar una validación cruzada (K-fold CV), el modelo obtuvo un Recall medio del 86.92% con una desviación estándar de apenas 0.0082. Estos resultados confirman que el modelo es altamente estable y no sufre de overfitting, garantizando un comportamiento fiable ante nuevos datos de clientes.

Conclusión Final de la Modelización

El modelo XGBoost fue seleccionado como el modelo de producción por ser el único capaz de romper el sesgo de la clase mayoritaria y alinearse con el objetivo estratégico del proyecto: la detección temprana y masiva de cancelaciones.